

基于改进粒子的车辆路径问题研究 群体优化算法

Lin Wang

长安大学汽车学院
南二环路中段, 西安, 中国

wangling_fighting@163.com

Guoliang Shen

长安大学电子与控制工程学院
南二环路中段, 西安, 中国

15771772135@163.com

Shifeng Niu

长安大学汽车学院
南二环路中段, 西安, 中国

nsf530@163.com

抽象的

为了提高粒子群优化的优化能力,提出一种改进的粒子群优化算法,并将其应用于解决车辆路径问题。基于线性和非线性惯性权重相结合的自适应粒子群优化算法有利于前期的局部搜索和后期的全局搜索。结合模拟退火算法,改进的粒子群优化算法可以避免局部最优和偏离最优解的情况。本文构建了车辆路径模型,并采用改进的粒子群优化算法来优化车辆路径问题。与遗传算法和改进粒子群优化算法相比,结果表明,改进粒子群优化算法能够快速、有效地得到车辆路径问题的最优解,说明改进粒子群优化算法是一种更为有效的解决车辆路径问题的方法。车辆路径问题。

关键词:粒子群优化, 车辆路径问题, 惯性权重,
模拟退火算法

1 简介

车辆路径问题 (VRP)由 Dantzig 和 Ramser 于 1959 年首次提出[1],是一个组合优化和整数规划问题。是指一系列的送货点(或收货点),形成适当的行驶路径,使车辆有序地通过它们,以达到一定的目标(如最短的距离、最少的成本、最少的时间等)。某些限制的存在。VRP被证明是NP完全的,存在于生活的方方面面,是交通、配送、物流等领域的重要问题。VRP的主要解决方案是启发式算法和精确算法。启发式算法中,多采用遗传算法、禁忌搜索算法、模拟退火算法和蚁群算法来求解VRP,并取得了良好的效果。

粒子群优化 (PSO)[2]是一种模拟鸟类飞行的仿生算法,具有个体数量少、计算简单、鲁棒性好的优点。PSO 在各类多维连续空间优化问题上都取得了相当好的性能[3]。本文提出了一种改进的粒子群优化算法(IPSO)。首先,基于自适应粒子群优化算法

给出了线性和非线性惯性权重,有利于前期的局部搜索和后期的全局搜索。然后,为了避免粒子群优化陷入局部最优,借鉴遗传算法的思想,提出了交叉的思想。IPSO具有较快的收敛速度,能够快速搜索全局最优解,提高算法的效率。

2 VRP说明

VRP一般描述为:一个物流中心共有车辆,每辆车的容量为 $q_k(k=1,2,\dots,K)$ 。现在有 L 个客户交付任务需要完成,使用 $1,2,\dots,L$ 代表任务。第 i 个客户送货车的容量为 $g_i(i=1,2,\dots,L)$,且最大 $g_i \leq \max q_k$ 。最终得到解决问题的最短路径。本文采用的数学模型是文献[4]提出的模型。物流中心编号表示为 0 ,客户交付任务编号表示为 $1,2,\dots,L$ 。配送任务和物流中心表示为 $i(i=0,1,2,\dots,L)$ 。定义如下:

和到

$$\begin{matrix} 1 & \text{客户交付任务我由车辆完成} & ; \\ 0 & \text{或者。} \end{matrix} \tag{1}$$

X_{智能}

$$\begin{matrix} 1 & \text{车辆从地点 } i \text{ 行驶至目的地 } j & ; \\ 0 & \text{或者。} \end{matrix} \tag{2}$$

在这里运输货物的成本是 C_{ij} ,表示车辆从始发地的成本到目的地 j 。这里的 C_{ij} 还可以代表其他含义,比如距离、时间等。车辆优化所需的条件用以下表达式表示:

分钟 和

$$\begin{matrix} C_{ij} & \text{;} \\ X_{ijk} & \text{;} \\ \text{说 } g_{yk} \text{ 是 } k & ; \\ \text{和到 } 1 & \text{ } 1,2,\dots,L \\ X_{ijk} & 0,1,\dots,1 \text{ 是 } k \text{ } ; \\ \text{西伊吉克} & 0,1,\dots,1 \text{ 是 } k \text{ } ; \\ X \times S(\text{智能}) & ; \\ X_{校准} & 0 \text{ 或 } 1, \text{ } 0,1,\dots,1 \text{ 是 } k \text{ } ; \\ y & \neq 0 \text{ } 1 \text{ } 0,1,\dots,1 \text{ 是 } k \text{ } \end{matrix} \tag{3}$$

由公式可知,运输所需的条件是:(1)每个客户配送任务都有一辆运输车辆; (2)每个客户配送任务都有一辆车要完成; (3)每次海关配送任务的需求总量不超过每辆车的总运力; (4)车辆路线总长度达到最小值。

3 改进的粒子群优化算法

IPSO是Kennedy和Eberhart于1995年提出的一种进化计算方法[5],该算法的思想源于模仿鸟类捕食[2]。假设有一群鸟在寻找食物,它们知道自己当前的位置以及距离食物的距离,但不知道食物的具体位置,所以它们需要搜索距离食物最近的鸟周围的区域。食物。在PSO中,搜索空间是鸟类的飞行空间,整个鸟群是搜索空间中的粒子群。每只鸟都被视为一个没有质量或体积的粒子,食物就是最终的最优解。每个粒子的状态对应于每个优化问题的解,并且每个粒子都有自己的自适应值,该自适应值由优化函数确定。自适应值最高的粒子就是最优粒子。每个粒子本身都有一定的速度来决定飞行的方向和距离。每个粒子在每一代中都在寻找自己的最优适应值,最终找到自身和整个种群的最优适应值。

3.1 简单粒子群优化算法

假设搜索空间的维数为 n ,总粒子数为 m ,和
迭代次数为 t 。第 i 个位置 粒子由矢量($V = v_1, v_2, \dots, v_n$)表示。
 $X = (x_1, x_2, \dots, x_n)$ 在 速度用向量表示。
第 i 个位置 迄今为止历史上的粒子搜索是用 表示的。这里最优位置对应的解就是最优解。在 g -th 的位置

粒子搜索是迄今为止整个种群历史中最好的位置,表示为($P_g = p_1, p_2, \dots, p_n$)。
通过向量 g_1, g_2, \dots, g_n 然后,更新以下表达式粒子
位置和速度:
$$V_i^{t+1} = wV_i^t + c_1r_1(P_{i1} - X_i^t) + c_2r_2(P_{g1} - X_i^t) \quad (4)$$

$$X_i^{t+1} = X_i^t + V_i^{t+1} \quad (5)$$

他们之中, $1 \leq i \leq m$ 并且在 n 维空间中进行搜索;
非负常数,通常称为加速因子或学习因子; w 是惯性 t 是当前的迭代次数
重量; r_1 和 r_2 是 $[0,1]$ 之间的随机数;一代,表示下一代的迭代
次数。
(5)可以看出,惯性权重 w 反映的效果由式 (4)和式
上一代速度对当前一代速度的影响。即,当前生成速度继承上一代速度的速度。较大的惯性权重适应于 n 维空间中粒子的大范围搜索。相反,较小的惯性权重适用于 n 维空间中粒子的小范围搜索。学习因素

C_1 反映自搜索最优位置对空间粒子搜索的影响;学习
因素 C_2 反映了粒子群搜索最优位置对粒子的影响
在太空中搜索。值为1 C_1 和 C_2 应该保持在一个相对平衡的范围内。如果值
 C_1 和 C_2 太大,即加速度太大,无法跳过最优解
搜索过程;如果值为1 C_1 和 C_2 太小,即加速度太小,粒子在搜索过程中会搜索到最优解的位置,而最优解
最终无法得到解决方案。因此,值1 C_1 和 C_2 一般都是订购的
 $C_1 = C_2 = 2$ 。在搜索过程中,粒子速度和位置的每个维度都应该有一个最大值
limit,这里定义的速度限制为 $-V_{d, \max}$ 和 $V_{d, \max}$ 和这里定义的位置限制是
当粒子的速度和位置超出搜索限制时

过程中,将粒子作为其边界值。Maurice[6]在分析了PSO的参数后,给出了PSO的收敛参数条件。

3.2 改进的粒子群优化算法

PSO的主要改进如下:

(1)采用线性和非线性相结合的方法改进惯性权重。惯性权重可以在迭代中平衡上一代速度与当代速度,即体现了PSO算法的搜索能力。随着迭代次数的增加,前期采用线性递减函数控制,有利于全局搜索;后期采用非线性递减函数进行控制,有利于局部搜索。

(2)结合模拟退火算法。PSO简单、快速、易于实现,但容易出现早熟收敛、容易陷入局部最优。模拟退火算法具有更好的局部搜索能力,为了进一步提高算法的有效性,结合模拟退火算法对PSO进行改进,避免陷入局部最优而偏离最优解。

3.2.1 线性和非线性惯性权重的组合

在搜索过程中,根据线性和非线性相结合的方法改进每个粒子的惯性权重。前期每个粒子按照线性递减的惯性权重进行搜索,进行前期广域搜索,保证搜索速度不会过快导致错过搜索的最佳解,并且具有较强的全局性搜索能力。随着迭代次数的增加,当迭代次数达到一定值时,根据非线性递减搜索每个粒子的惯性权重。

由于粒子已经达到最优值,粒子的搜索范围较小,需要加快搜索速度。目的是保证粒子能够快速有效地搜索到最优解。

线性和非线性惯性权重的改进表达式如下:

$$W = W_{\max} - \frac{W_{\max} - W_{\min}}{T} \cdot t \quad (1) \quad ;$$

$$W = W_{\min} + (W_{\max} - W_{\min}) \cdot e^{-\frac{t}{T}} \quad (2) \quad , \quad (6)$$

数,其范围 W_{\min} 为最大惯性权重,即初始惯性权重;其中, h 为迭代次数,其范围为 $0 \leq h \leq T$ 。

T 为最大迭代次数; W 为 时惯性重量的值; H T

迭代过程中的迭代次数 $t = h$; W_1 是惯性权重的值,当

迭代过程中的迭代次数 $t \leq h$; W_2 为惯性重量时的值

迭代过程中的迭代次数 $t = h$ 。

在使用惯性权重的线性和非线性组合的过程中,粒子为 $t \leq h$

初始阶段搜索 () 根据线性递减的惯性权重。当 $t = h$ 时,记录此时惯性权重的值,将线性递减惯性权重转换为非线性递减惯性权重。然后根据非线性递减惯性权重搜索粒子。

3.2.2 线性和非线性惯性权重的组合

模拟退火算法源于固体退火原理。它首先由N.Metropolis等人提出。1953年[7]并被引入组合优化

由 S.Kirkpatrick 于 1983 年提出。它将固体加热到更高的温度,然后缓慢冷却。在加热过程中,固体中的粒子随着温度的升高而随机运动,能量得以增加;当它缓慢冷却时,颗粒在每个温度下都能达到平衡。当固体温度达到常温时,

固体中的粒子将达到基态,内能将降至最低。

在组合优化领域,固体的退火过程可以表述为:

固体的内能相当于组合优化问题中的评价函数;固体的状态相当于问题的解决;固体的最小内能相当于问题的最优解。

在优化过程中,PSO每次都会选择当前最优解,容易陷入局部最优而偏离全局最优。然而混合模拟退火算法可以很好地克服这个缺点。模拟退火算法在搜索过程中引入随机因素,能够以给定的概率接受当前差异的解,因此能够很大程度上跳出局部最优解,达到全局最优解。

假设 $C(s)^t$ 是评价函数,其中 E 为能量差且温度为 T 。 s^t 是当前状态。目前的 $T P(E)$ 是温度降低的概率

。那么,模拟退火算法的数学描述过程如下所示:

(1) 如果 $C(s^{t+1}) \leq C(s^t)$, 即当下一状态的评价函数大于或等于当前状态的评价函数的值时,粒子总是接受移动;

(2) 如果 $C(s^{t+1}) > C(s^t)$, 也就是说,当下一状态的评价函数小于当前状态的评价函数值时,粒子会以给定的概率接受运动,并且这个概率会随着迭代次数的增加而减小。

数学描述过程中的概率表示为:

$$P = \frac{\exp(-\frac{C(s^{t+1}) - C(s^t)}{K \cdot T})}{1 + \exp(-\frac{C(s^{t+1}) - C(s^t)}{K \cdot T})} \quad (7)$$

其中, K 为常数, $E \leq 0$ 。

由式 (7) 可知,随着温度 T 的增加,接受移动的概率增加。随着温度 T 的降低,接受移动的概率减小。反之,温度越低,冷却的概率就越小。

这样,在粒子群寻找最优解的过程中,如果下一状态的解优于当前的解(下一状态的自适应值大于当前的自适应值),则下一状态的解为用于替换当前解,即更新当前解。如果下一状态的解比当前的解差,则根据模拟退火算法的原理,以一定的概率接受下一状态的解,从而以一定的概率将其作为当前解。理论上,模拟退火算法已被证明是一种全局优化算法,收敛到全局最优的概率为1。

应用模拟退火算法后,粒子在寻找最佳自适应值时会接受概率较低的粒子。因此,初始温度应足够大,以保证粒子在初始阶段有较强的初始跳跃。这里的初始温度定义为:

$$T_0 = \frac{C(p_b) - C(p_w)}{\ln p_s} \quad (8)$$

他们之中, $C(p_b)$ 为初始时最优粒子的评价函数值

定义随机粒子; $C(p_w)$ 是当 p 是最优粒子被替换的概率时最差粒子的评价函数值

定义初始随机粒子;是初始温度下最差的粒子。

轮盘游戏也称为比例选择法。基本思想是每个个体的概率与其适应值成正比。具体计算过程如下：

(1) 计算粒子群中每个粒子的自适应值N为粒子群大小； $C(i = 1, 2, \dots, N)$ 和

(2) 计算每个粒子可以传递给下一代的概率：

$$P(X)_i = \frac{C(X)_i}{\sum_{j=1}^N C(X)_j} \tag{9}$$

(3) 计算每个粒子的累积概率：

$$q_i = \sum_{j=1}^i P(X)_j \tag{10}$$

(4) 生成在 [0,1] 之间均匀分布的随机数r；

(5) 如果 $q_i \geq r$ ，选择 X_i ；否则，选择 X_{k+1} ，使 $q_{k+1} \geq r$ 。

在该算法中，遗传到下一代的跳跃概率为： $\frac{(d \cdot p_i \cdot d \cdot p_g)}{(\sum_{i=1}^N (d \cdot p_i \cdot d \cdot p_g))}$ ，以及每个粒子的概率

$$P(X)_i = \frac{\sum_{j=1}^N (C(p_i \cdot C(p_g))}{\sum_{j=1}^N (C(p_i \cdot C(p_g))} \tag{11}$$

因此，根据概率，当代粒子正在取代当代粒子。 $P(X)_i$ ，轮盘赌策略用于确定是否更多

添加模拟退火算法后，具体搜索步骤设计如下：

(1) 初始化粒子群。定义粒子群数为m，搜索次数，空间维度为d（每个粒子的速度和位置的变量数量为d）。定义代数的初始迭代 $t = 1$ ，最大迭代次数为T。定义随机参数 r_1 和 r_2 ；定义学习因子（加速因子）为 C_1 和 C_2 。最初的惯性权重定义为 $w_t = w_{\max} - \frac{(w_{\max} - w_{\min}) \cdot t}{T}$ ，惯性权重 w_{\min} 终止。初始位置 p_t 和定义的初始速度。我们给出了每个粒子的初始温度值 T_0 是

(2) 计算粒子群体中每个粒子的初始适应值。每个粒子的初始自适应值是根据给定粒子的初始位置和初始速度计算的。

(3) 根据式(6)计算惯性权重。

(4) 根据式(4)、(5)更新下一代各粒子的位置和速度。

(5) 根据更新后粒子的速度和位置计算自适应值，确定下一代粒子的适应度和当代自适应值的大小。如果下一代粒子的自适应值优于当前粒子，则下一代粒子

以粒子自适应值作为粒子的最佳位置 p_t 。否则，轮盘赌策略用于允许选择一些粒子并接受同时更新的粒子，而其余粒子保持不变。 p_t 更多

- (6)降低温度。选择温度反转函数为常数。 $TK = TK-1$, 在哪里
- (7) 转步骤(3),直至达到最大迭代次数。如果满意,则继续下一步。
- (8)输出迭代后粒子的最优位置和速度。

4 应用

4.1 VRP模型

参考文献[8]的思想,建立VRP模型如下:
构建车辆路径维度,设置为2L维度。中心仓库对客户进行配送,因此配送过程涉及配送目标任务的车辆选择和每个任务车辆的配送订单选择。因此,对于车辆数量k和配送顺序r, L个配送任务被分为两个L

X_k (配送目标,任务车辆选择)和 X_r (分布维度位置向量:
每个任务车辆的顺序)。相应的速度矢量为 V_k 和 V_r , 分别。
例如,有10个客户交付任务需要完成。仓库由中央仓库发货,中央仓库有4辆车,对应的位置向量可以表示为:

交付任务数量	1	2	3	4	5	6	7	8	9	10
X_k	1	2	2	2	3	3	3	3	4	4
X_r	1	3	1	2	1	4	2	3	1	2
从交付任务可以看出:										
车辆	1	0	1	0						
车辆	2	0	3	4	2	0				
车辆	3	0	5	7	8	6	0			
车辆	4	0	9	10	0					

4.2 算法实现

- (1) 初始化粒子群。定义值 X_k $1 \sim k$ 之间的整数
(车辆号码)。 X_r 的值为 $1 \sim L$ 之间的实数 (发货数量)
任务) 的价值 V_k 是 $t = 1$ 之间的整数 $-(k-1) \sim (k-1)$ 。定义参数 r_1 , r_2 , C_1 和 C_2 。定义初始迭代代数 (2) 计算粒子群中每个粒子 p , 最大迭代次数为 T 。
的初始自适应值。根据给定粒子的初始位置和初始速度计算每个粒子的初始自适应值。
- (3) 根据式(6)计算惯性权重。
- (4) 根据式(4)和式(5)更新下一代各粒子的速度和位置。
- (5)根据更新后粒子的速度和位置计算自适应值,确定下一代粒子的适应度和当代自适应值的大小。如果下一代粒子的自适应值优于当前粒子,则下一代粒子
- 以粒子自适应值作为粒子的最佳位置 p_{best}^t 。否则,轮盘赌 p_{best}^t 更多
策略用于允许选择一些粒子并接受同时更新的粒子,而其余粒子保持不变。

- (6)降低温度。选择温度反转函数为常数。 $TK = TK-1$, 在哪里
- (7) 转步骤(3),直至达到最大迭代次数。如果满意,则继续下一步。
- (8)输出迭代后粒子的最优位置和速度。

4.3 仿真与分析

本文对文献[9,10]中的情况进行了仿真,并与文献[9,10]的结果进行了比较
文献[9,10]中提出的算法。案例如下:
某物流中心拥有车辆2辆,每辆载重8吨。有8个客户需要完成配送任务,每个客户之间的距离和需求数量如图所示

表1 最终得到解决问题的最短路径。其中, c_{ij} 代表物流中心与每个客户之间的距离,需求数量的单位为吨。

C_{ij}	0	1	2	3	4	5	6	7	8
0	0	4	6	7.5	9	20	10	16	8
1	4	0	6.5	4	10	5	7.5	11	10
2	6	6.5	0	7.5	10	10	7.5	7.5	7.5
3	7.5	4	7.5	0	10	5	9	9	15
4	9	10	10	10	0	10	7.5	7.5	10
5	20	5	10	5	10	0	7	9	7.5
6	10	7.5	7.5	9	7.5	7	0	7	10
7	16	11	7.5	9	7.5	9	7	0	10
8	8	10	7.5	15	10	7.5	10	10	0
数量 要求的	0	1	2	1	2	1	4	2	2

算法参数定义如下:
学习因子选为 $c1 = c2 = 1$ 。 r_1 和 r_2 是 $[0,1]$ 之间的随机数。
前阶段最大迭代次数为 $T1 = 500$ $h = T1 / 2$ 中的最大迭代次数
后期 $T2 = 500$ 。式(6)中,前级参数定义为 $(16 / (T1^3))^{1/3}$,
 $h_1(t) = t / T_1$ 和 赫特 $h = T2 / 2$,
 $h_1(t) = t / T_2$ 和 赫特 $(16 / (T2^3))^{1/3}$, 后期参数定义为
。其中,定义了本文使用的IPSO,运行结果 $= 0.95$ 。
如表2所示。

表2 IPSO的运行结果

运行时间	1	2	3	4	5	6	7	8	9	10
最终距离 运行时	67.5	68	67.5	68	69	67.5	67.5	68	67.5	67.5
间 最终距离	11	12	13	14	15	16	17号	18	19	20
运行时间 最终距离	69	67.5	67.5	68	67.5	68	68	67.5	67.5	67.5
表格和图形应	21	22	23	24	25	26	27	28	29	30
紧挨着文本中第一	67.5	67.5	67.5	69	68	67.5	67.5	69	68	67.5

个引用的位置放置。所有图、表均应使用阿拉伯数字编号。表格标题应位于表格上方居中。
图标题应位于图下方居中,如图 1 所示。

配送任务中每辆车的路线顺序为0→4→7→6→0，
0→1→3→5→8→2→0
分别。
将IPSO的结果与PSO和改进的遗传算法的结果进行比较。

表3 表参数

算法	最短距离	平均距离67.83	运行时间
我是	67.5		0.032秒
粒子群算法	67.5	68.375	0.024秒
改善遗传 算法	67.5	68.3	0.032秒

从表3可以看出,IPSO在运行30次的前提下,平均距离优于其他两种算法,且运行时间较短。

可见IPSO在VRP方面取得了不错的效果。与PSO和改进的遗传算法相比,IPSO具有效率高、优化效果好、搜索结果高、质量高等优点。因此,IPSO对于VRP是有帮助和有效的。

5.结论

为了克服收敛速度慢和局部最优的缺点,本文提出了IPSO。在PSO中引入线性和非线性惯性权重的结合,提高了前期的局部搜索速度和后期的全局搜索速度。并应用遗传算法对PSO进行了进一步改进,有效提高了精度和速度。

通过算例的仿真分析,IPSO可以在较短的时间内搜索到最优路径,得到最短距离。与PSO和改进的遗传算法相比,结果表明IPSO可以提高搜索最佳路径的成功率,是更好、更有效的VRP方法。

参考

乔治·伯纳德·丹齐格;约翰·休伯特·拉姆瑟(1959)。卡车调度问题[C]。
管理科学。6 (1) :80-91。
Kennedy J, Eberhart R C. 粒子群优化[A].Proc.IEEE 国际神经网络会议, IV[C].新泽西州皮斯卡拉韦:IEEE 服务中心,1995。
1942-1948。
Eberhart RC, Shi Y. 粒子群优化:发展、应用和资源[C]。
过程。2001 年进化计算大会。新泽西州皮斯卡塔韦:IEEE Press,2001.81-86。
李军,郭刚。物流配送车辆优化调度理论与方法[M]。
北京:中国物资出版社,2001.76-77。
Eberhart RC, Kennedy J. 粒子群理论的新应用[C].第六届国际微型机械与人类科学研讨会论文集。美国新泽西州皮斯卡塔韦:IEEE 服务中心,1995 年:39-43。
Steinbrunn M, Moerkotte G, Kemper A. 连接排序问题的启发式和 Ran2 优化优化[J]. VLDB杂志,1997,6 (3) :8-17。
石Y,Eberhart R C.粒子群优化的实证研究[A]。1999年进化计算大会论文集[C].新泽西州皮斯卡塔韦:IEEE 服务中心,1999 年。
1945 年-
1950年。
石Y,Eberhart R C.粒子群优化的实证研究[A]。1999年进化计算大会论文集[C].新泽西州皮斯卡塔韦:IEEE 服务中心,1999 年。
1945 年-
1950年。
肖建梅、李军军、王锡槐。改进的粒子群优化算法解决车辆路径问题。计算机集成制造系统,2005,11(4):577-581。
Zhang Yuxing, Fan Jianhua, Xu Jiangang, Chen Dongsheng. Improved genetic algorithm for vehicle routing problem. Journal of Tianjin University of Technology, 2006, 22 (5),:79 - 82.